

عنوان مقاله

ارائه یک سیستم تشخیص نفوذ ترکیبی مبتنی بر جنگل تصادفی و منطق فازی برای شناسایی حملات DDoS با استفاده از مجموعه داده CICIDS2017

نویسنده : محمد حسین تقدیری

گروه مهندسی کامپیوتر، دانشگاه آزاد اسلامی شیراز، ایران

ایمیل : mhtaghdiri80@gmail.com

گیتهاب : <https://github.com/taghdirii/CICIDS2017-DDoS-Hybrid-IDS>

چکیده

با گسترش وابستگی سازمان‌ها به شبکه‌ها و خدمات برخط، شناسایی سریع و دقیق حملات منع سرویس توزیع‌شده (DDoS) به یکی از مسائل مهم امنیت شبکه تبدیل شده است. اگرچه روش‌های یادگیری ماشین توانایی بالایی در تشخیص الگوهای پیچیده ترافیک شبکه دارند، ایجاد هشدارهای مثبت کاذب همچنان یکی از چالش‌های مهم سامانه‌های تشخیص نفوذ است. در این پژوهش، یک سیستم تشخیص نفوذ ترکیبی مبتنی بر جنگل تصادفی و منطق فازی برای شناسایی حملات DDoS ارائه شده است. در مرحله نخست، داده‌های منتخب از مجموعه CICIDS2017 پس از حذف مقادیر نامعتبر و رکوردهای تکراری پاک‌سازی شدند. سپس، در هر بخش ارزیابی، ۲۰ ویژگی برتر با استفاده از اهمیت ویژگی در جنگل تصادفی و صرفاً بر روی داده‌های آموزشی انتخاب شدند. برای ارزیابی پایدارتر، از اعتبارسنجی متقابل طبقه‌بندی‌شده پنج‌تایی استفاده شد. مدل پایه Random Forest با ۱۰۰ درخت آموزش داده شد و خروجی احتمال حمله آن با یک سیستم استنتاج فازی مبتنی بر نرخ بسته‌ها، نرخ بایت‌ها و تعداد پرچم‌های SYN ترکیب گردید. امتیاز نهایی ترکیبی با وزن‌های ۰/۷ برای Random Forest و ۰/۳ برای بخش فازی محاسبه شد. نتایج پنج‌تایی نشان داد مدل ترکیبی به Accuracy برابر ۹۹/۹۶۸۹ درصد، Precision برابر ۹۹/۹۵۸۶ درصد، Recall برابر ۹۹/۸۶۴۹ درصد و F1 برابر ۹۹/۹۱۱۷ درصد دست یافت. همچنین FPR از ۰/۰۱۰۲۰۶ درصد در مدل پایه به ۰/۰۰۸۸۶۸ درصد کاهش یافت که بیانگر کاهش نسبی ۱۳/۱۱ درصدی نرخ مثبت کاذب است. مقایسه با SMOTE+Random Forest نیز نشان داد متعادل‌سازی کلاس‌ها در این آزمایش به کاهش FPR منجر نشده است.

واژگان کلیدی : تشخیص نفوذ، حمله DDoS، جنگل تصادفی، منطق فازی، CICIDS2017، یادگیری ماشین

امنیت شبکه یکی از مؤلفه‌های اساسی زیرساخت‌های فناوری اطلاعات است و حملات منع سرویس توزیع‌شده (DDoS) به دلیل توانایی ایجاد حجم زیادی از ترافیک و اختلال در دسترسی کاربران، تهدیدی مهم برای سامانه‌های متصل به شبکه محسوب می‌شوند. سامانه‌های تشخیص نفوذ باید بتوانند میان ترافیک عادی و مخرب تمایز ایجاد کنند و در عین حال نرخ هشدارهای نادرست را پایین نگه دارند.

با افزایش حجم و تنوع داده‌های ترافیکی، روش‌های یادگیری ماشین به‌طور گسترده در سامانه‌های تشخیص نفوذ مورد استفاده قرار گرفته‌اند. مجموعه داده CICIDS2017 نیز یکی از مجموعه داده‌های شناخته‌شده در این حوزه است که برای ارزیابی روش‌های تشخیص نفوذ و انواع مختلف ترافیک شبکه ایجاد شده است.

الگوریتم Random Forest به دلیل استفاده از مجموعه‌ای از درخت‌های تصمیم و توانایی مناسب در مدل‌سازی روابط غیرخطی، یکی از روش‌های پرکاربرد در طبقه‌بندی ترافیک شبکه محسوب می‌شود. با این حال، خروجی یک طبقه‌بند یادگیری ماشین ممکن است در برخی شرایط باعث ایجاد هشدارهای مثبت کاذب شود. کاهش چنین هشدارهایی به‌ویژه در سامانه‌های تشخیص نفوذ اهمیت دارد، زیرا تعداد زیاد هشدارهای نادرست می‌تواند موجب افزایش بار تحلیل و کاهش اعتماد به سامانه شود.

از سوی دیگر، منطق فازی امکان استفاده از متغیرهای زبانی و قواعد اگر-آنگاه را برای تصمیم‌گیری فراهم می‌کند و می‌تواند اطلاعات عددی مربوط به وضعیت ترافیک را به یک ارزیابی ریسک قابل تفسیر تبدیل کند.

بر این اساس، در پژوهش حاضر یک معماری ترکیبی پیشنهاد می‌شود که در آن احتمال حمله تولیدشده توسط Random Forest با یک سیستم استنتاج فازی ترکیب می‌شود. نوآوری اصلی پژوهش، استفاده از لایه فازی به‌عنوان سازوکار **تعدیل‌کننده تصمیم Random Forest با هدف کاهش مثبت‌های کاذب است**. همچنین، روش پیشنهادی با Random Forest پایه و SMOTE+Random Forest مقایسه می‌شود.


برای جلوگیری از نشت اطلاعات، انتخاب ویژگی **داخل هر Fold** و فقط با استفاده از داده‌های آموزشی همان Fold انجام شد. سپس ۲۰ ویژگی دارای بیشترین اهمیت برای آموزش و ارزیابی مدل همان Fold انتخاب شدند.

در میان ویژگی‌هایی که در Fold های مختلف به‌صورت پایدار در رتبه‌های بالا ظاهر شدند، می‌توان به موارد زیر اشاره کرد:

- Avg Bwd Segment Size
- Bwd Packet Length Max
- Average Packet Size
- Max Packet Length
- Packet Length Variance
- Bwd Packet Length Std
- Packet Length Std
- Subflow Fwd Packets
- Subflow Fwd Bytes
- act_data_pkt_fwd

پایداری حضور این ویژگی‌ها در چند Fold نشان می‌دهد که ویژگی‌های مرتبط با اندازه بسته‌ها و رفتار جریان‌های رفت و برگشتی نقش مهمی در تفکیک ترافیک عادی و DDoS داشته‌اند.

شکل ۱. مقایسه عملکرد مدل‌ها بر اساس اعتبارسنجی متقابل ۵-بخشی



۲.۳ مدل Random Forest

مدل پایه پژوهش با استفاده از RandomForestClassifier و شامل ۱۰۰ درخت تصمیم ایجاد شد. پارامتر random_state برابر ۴۲ و n_jobs=-1 در پیاده‌سازی مورد استفاده قرار گرفت. برای ارزیابی مدل، داده‌ها با استفاده از **Stratified 5-Fold Cross-Validation** به پنج بخش تقسیم شدند. در هر Fold، چهار بخش برای آموزش و یک بخش برای آزمون مورد استفاده قرار گرفت. خروجی مدل Random Forest احتمال تعلق هر نمونه به کلاس حمله بود و آستانه ۰/۵ برای تبدیل احتمال به برچسب نهایی استفاده شد.

۲.۴ سیستم استنتاج فازی

برای بخش فازی سه شاخص ترافیکی به عنوان ورودی در نظر گرفته شدند:

1. Flow Packets/s

2. Flow Bytes/s

3. SYN Flag Count

مقادیر Flow Packets/s و Flow Bytes/s با استفاده از صدک‌های اول و ۹۹ام نرمال‌سازی شدند. این پارامترهای نرمال‌سازی فقط از داده‌های آموزشی هر Fold محاسبه شدند و سپس بر روی داده‌های آزمون همان Fold اعمال شدند.

سیستم فازی با استفاده از توابع عضویت کم، متوسط و زیاد، میزان ریسک حمله را محاسبه می‌کند.

خروجی سیستم فازی با عنوان **Attack Risk** در بازه صفر تا ۱۰۰ تعریف شد و پس از نرمال‌سازی به یک مقدار احتمال در بازه صفر تا یک تبدیل گردید.

قواعد اگر-آنگاه سیستم فازی بر اساس ترکیب سطوح ترافیکی تعریف شدند تا در شرایطی که شاخص‌های رفتاری ترافیک احتمال فعالیت مخرب را افزایش می‌دهند، ریسک بیشتری به نمونه اختصاص داده شود.

۲.۵ مدل ترکیبی پیشنهادی

در معماری پیشنهادی، خروجی احتمال حمله Random Forest با احتمال متناظر حاصل از سیستم فازی ترکیب می‌شود.


فرمول امتیاز ترکیبی به صورت زیر است:

$$Hybrid\ Score = 0.7 \times RF\ Probability + 0.3 \times Fuzzy\ Probability$$

در صورتی که امتیاز ترکیبی بزرگتر یا مساوی ۰/۵ باشد، نمونه به عنوان حمله DDoS و در غیر این صورت به عنوان ترافیک عادی طبقه‌بندی می‌شود.

این ساختار با هدف استفاده همزمان از قدرت طبقه‌بندی Random Forest و قابلیت تعدیل تصمیم بر اساس شاخص‌های رفتاری ترافیک طراحی شده است.

شکل ۲. معماری سیستم پیشنهادی Random Forest + Fuzzy



۲.۶ روش ارزیابی

برای افزایش قابلیت اعتماد نتایج، از ۵ **Fold Stratified Cross-Validation**-استفاده شد.

در هر Fold ، مراحل زیر به صورت مستقل انجام شدند:

1. تقسیم داده به آموزش و آزمون
 2. انتخاب ویژگی فقط با داده آموزش
 3. آموزش Random Forest
 4. آموزش سیستم ترکیبی RF+Fuzzy
 5. اجرای مدل روی داده آزمون
 6. محاسبه معیارهای ارزیابی
- همچنین برای مقایسه اثر متعادل سازی کلاس ها، روش **SMOTE+Random Forest** نیز بررسی شد .
SMOTE فقط روی بخش آموزشی هر Fold اعمال شد و داده آزمون بدون تغییر باقی ماند.

معیارهای ارزیابی شامل موارد زیر بودند:

- Accuracy
- Precision
- Recall
- F1-Score
- False Positive Rate (FPR)

۳ نتایج

۳.۱ مقایسه عملکرد مدل‌ها

نتایج نهایی حاصل از پنج Fold در جدول ۱ ارائه شده است.

جدول ۱. مقایسه عملکرد سه روش در 5-Fold Cross-Validation

مدل	(%) Accuracy	(%) Precision	(%) Recall	(%) F1	(%) FPR
Random Forest	0.0115 ± 99.9690	0.0230 ± 99.9523	0.0467 ± 99.8719	0.0327 ± 99.9121	0.004928 ± 0.010206
SMOTE + RF	0.0112 ± 99.9673	0.0291 ± 99.9429	0.0455 ± 99.8719	0.0319 ± 99.9074	0.0062 ± 0.0122
RF + Fuzzy	0.0114 ± 99.9689	0.0245 ± 99.9586	0.0482 ± 99.8649	0.0324 ± 99.9117	0.005245 ± 0.008868

نتایج نشان می‌دهند که مدل RF+Fuzzy کمترین نرخ مثبت کاذب را در میان سه روش به دست آورده است.

FPR مدل پایه Random Forest برابر با ۰/۰۱۰۲۰۶ درصد بود، در حالی که این مقدار در مدل ترکیبی به ۰/۰۰۸۸۶۸ درصد کاهش یافت. بنابراین، کاهش نسبی FPR برابر با:

۱۳/۱۱ درصد به دست آمد.

همچنین Precision از ۹۹/۹۵۲۳ درصد به ۹۹/۹۵۸۶ درصد افزایش یافت.

۳.۲ تحلیل نتایج

مقایسه نتایج نشان می‌دهد که مزیت اصلی روش پیشنهادی در کاهش مثبت‌های کاذب است.

مدل RF+Fuzzy توانست در مقایسه با Random Forest پایه:

- FPR را کاهش دهد؛
 - Precision را افزایش دهد؛
 - Accuracy را تقریباً در همان سطح حفظ کند؛
 - F1-Score را تقریباً در همان سطح حفظ کند.
- در مقابل، Recall از ۹۹/۸۷۱۹ درصد به ۹۹/۸۶۴۹ درصد کاهش یافت.

بنابراین نمی‌توان ادعا کرد که مدل ترکیبی در تمام معیارها بهتر از Random Forest است. مزیت اصلی روش پیشنهادی، کاهش هشدارهای مثبت کاذب با حفظ عملکرد کلی بسیار بالا است.

۳.۳ مقایسه با SMOTE

روش SMOTE+Random Forest نیز برای بررسی اثر متعادل‌سازی کلاس‌ها مورد ارزیابی قرار گرفت.

نتایج نشان داد:

$$\text{FPR} = \text{SMOTE+RF} = 0.122 \text{ درصد}$$

در حالی که:

$$\text{FPR} = \text{RF} = 0.1026 \text{ درصد}$$

و:

$$\text{FPR} = \text{RF+Fuzzy} = 0.08868 \text{ درصد}$$

بنابراین در این آزمایش، SMOTE نه تنها موجب کاهش FPR نشد، بلکه FPR بیشتری نسبت به مدل پایه ایجاد کرد.

این نتیجه نشان می‌دهد که برای مسئله مورد بررسی، افزایش نمونه‌های مصنوعی کلاس اقلیت الزاماً به کاهش هشدارهای مثبت کاذب منجر نمی‌شود و استفاده از اطلاعات رفتاری ترافیک در قالب سیستم فازی می‌تواند برای هدف مشخص کاهش FPR مؤثرتر باشد.

۳.۴ پایداری انتخاب ویژگی

بررسی پنج Fold نشان داد که ویژگی‌هایی مانند:

Avg Bwd Segment Size

Bwd Packet Length Max

Average Packet Size

Max Packet Length

Bwd Packet Length Std

و

Packet Length Std

در اکثر Fold ها در میان رتبه‌های نخست اهمیت قرار گرفتند.

این موضوع نشان می‌دهد که ویژگی‌های مربوط به طول بسته‌ها، اندازه سگمنت‌ها و رفتار جریان‌های شبکه، نقش قابل توجهی در تشخیص ترافیک DDoS در داده مورد استفاده دارند.

۳.۵ بحث و محدودیت‌ها

یکی از محدودیت‌های این پژوهش آن است که ارزیابی بر اساس دو فایل منتخب از CICIDS2017 انجام شده است؛ بنابراین نتایج را نمی‌توان بدون آزمایش بیشتر به تمام انواع حملات یا محیط‌های عملیاتی واقعی تعمیم داد.

همچنین اگرچه استفاده از 5-Fold Stratified Cross-Validation نسبت به یک تقسیم آموزش/آزمون منفرد ارزیابی پایدارتر و قابل‌دفاع‌تری فراهم می‌کند، اما تقسیم تصادفی داده‌ها ممکن است به دلیل شباهت جریان‌های شبکه، برآورد خوش‌بینانه‌ای ایجاد کند.

در مطالعات آینده می‌توان از **تقسیم زمانی داده‌ها**، مجموعه‌های حمله متنوع‌تر و روش‌های مستقل برای بهینه‌سازی وزن‌های ترکیب Random Forest و سیستم فازی استفاده کرد.

[1]

I. Sharafaldin, A. H. Lashkari, and A. A. Ghorbani, "Toward Generating a New Intrusion Detection Dataset and Intrusion Traffic Characterization," *Proceedings of the 4th International Conference on Information Systems Security and Privacy (ICISSP)*, 2018.

[2]

L. Breiman, "Random Forests," *Machine Learning*, vol. 45, pp. 5–32, 2001.

[3]

L. A. Zadeh, "Fuzzy Sets," *Information and Control*, vol. 8, no. 3, pp. 338–353, 1965.

[4]

A. Khraisat, I. Gondal, P. Vamplew, and J. Kamruzzaman, "Survey of intrusion detection systems: techniques, datasets and challenges," *Cybersecurity*, vol. 2, no. 20, 2019.

[5]

N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, "SMOTE: Synthetic Minority Over-sampling Technique," *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.
